

Pseudoetiquetado para el análisis de polaridad en tuits: un primer acercamiento

Diana Jimenez, Marco A. Cardoso-Moreno, Cesar Macias

Abstract Keywords: BCI · EEG · ERP · P300

1 Introducción

Las redes sociales hoy en día forman una parte de la vida cotidiana para la población en general, ya sea para cuestiones de relaciones interpersonales, *net-working* e incluso, para la consulta y diseminación de información [12, 15, 16]. A partir de este incremento en el uso de redes sociales, intensificado en años recientes gracias a la pandemia de COVID-19 [6], es que estas plataformas se han vuelto parte del discurso público, ya que los algoritmos utilizados en las mismas permiten a sus usuarios interactuar con diversos grupos sociales, lo que los mantiene al tanto de los eventos y problemáticas actuales [3].

En particular, Twitter no presenta muchas restricciones sobre el contenido de las publicaciones que sus usuarios pueden efectuar por lo que, en general, suelen ser sobre cualquier tema, esta aparente libertad que la plataforma provee es la principal razón de que esta red social tiene preferencia entre los internautas para, en ella, mostrar sus opiniones [16].

Dentro de las áreas de procesamiento de lenguaje natural (PLN) y lingüística computacional existe la tarea de análisis de opiniones, que consiste en, mediante el análisis del texto donde un comentario opinión fue expresado, determinar el la opinión que una persona sobre el tema en cuestión [13]; el análisis de la polaridad en una opinión se considera, a su vez, una subtarea de este campo [4]. Determinar la polaridad de un texto se refiere, entonces, a clasificar, dado un texto, si la opinión que se ha vertido en este es positiva o negativa, es decir, qué tan polarizada es.

2 Revisión de la literatura

La clasificación de textos, por su parte, puede llevarse a cabo mediante estrategias de apredizaje automática, específicamente, aprendizaje supervisado. Estas técnicas han sido, y siguen siendo, ampliamente utilizadas en la clasificación de textos para diferentes tareas, siendo una de las más destacadas el análisis de sentimientos. Por ejemplo, en [7] se hace uso de redes neuronales recurrentes (RNR), específicamente redes Bi-LSTM (del inglés *Bi Long Short-Term Memory*) para esta tarea; de manera similar, [1] utilizan Twitter como un medio donde la gente puede expresar síntomas de depresión que requieren ser reportados por un individuo con esta afectación psicológica para detectar dicho

padecimiento de manera temprana, para lo cual utilizaron RNR tradicionales, así como redes LSTM; en [17] utilizan el modelo de transforme RoBERTa-GRU (del inglés *Robustly Optimized BERT Pretraining Approach* y *Gated Recurrent Units*) para la clasificación de sentimientos en diversos datasets considerados como *baselines*; por su parte, [5] utilizan el clasificador Naive-Bayes para la misma tarea, apoyándose del recurso léxico *sentiwordnet* para agregar a cada palabra un puntaje de sentimiento positivo, negativo u objetivo.

En cuanto a la tarea específica de análisis de polaridad en texto, uno de los primeros trabajos que se llevaron a cabo fue aquel de [14], en el cual se utilizaron clasificadores tradicionales, tales como: Naive Bayes, Entropía Máxima y Máquinas de Soporte Vectorial (SVM, del inglés *Support Vector Machines*) para la clasificación de polaridad de reseñas (en inglés) de películas; en [9] se realiza un estudio sobre el impacto de la negación en la clasificación de la polaridad en tuits en español, concluyendo que el tomar en cuenta dicho aspecto contribuye significativamente a una mejora en la clasificación de la polaridad; además, se encuentra el trabajo de [11], donde se utilizan múltiples clasificadores, tales como: Entropía Máxima, Naive Bayes Multinomial, SVMs y BETO, un modelo BERT (del inglés *Bidirectional Encoder Representations from Transformers*) entrenado con un corpues en español, para obtener la polaridad de tuits en español, lo que incluía encabezados de noticias, los hilos de la conversación correspondiente a dichos encabezados, tuits citados y los hilos de conversación que se generaron a partir de éstos.

Por otro lado, se ha observado que los modelos de aprendizaje de máquina y aprendizaje profundo suelen ver afectado su desempeño cuando no se cuenta con suficientes datos, por lo que se suelen utilizar técnicas de aumento de datos y, en los casos en los que no se puede preservar las etiquetas, pseudoetiquetado, tal es el caso de [2], donde se utilizó dicha técnica para mejorar el desempeño de diversas arquitecturas de redes neuronales para la tarea de detección de agresión en redes sociales. También destaca el trabajo de [10], donde se hace uso del modelo DistilBERT en la tarea de clasificación de preguntas para su incorporación de sistemas tipo chatbots dedicados a responder preguntas, para contravenir la falta de los datos etiquetados se utilizan técnicas de pseudoetiquetado, obteniendo como resultado que el modelo cuyo banco de datos de entrenamiento datos pseudoetiquetados presentó un mejor desempeño que aquellos con los cuáles no se utilizó dicha técnica para su entrenamiento. Por último, en [8] se hace uso del pseudoetiquetado para la mejora en los sistemas de detección de noticias, ya que el etiquetado manual de texto suele ser una tarea laboriosa, sobre todo dada la ingente cantidad de recursos disponibles en internet, lo que resulta en una falta de datos etiquetados disponibles; en este trabajo se observó un incremento en el desempeño de clasificación de entre el 2% y 3% cuando se agregaron nuevos datos cuya etiqueta fue asignada mediante algún algoritmo.

References

1. Apoorva, A., Goyal, V., Kumar, A., Singh, R., Sharma, S.: Depression detection on twitter using rnn and lstm models. In: Woungang, I., Dhurandher, S.K.,

- Pattanaik, K.K., Verma, A., Verma, P. (eds.) *Advanced Network Technologies and Intelligent Computing*. pp. 305–319. Springer Nature Switzerland, Cham (2023)
2. Aroyehun, S.T., Gelbukh, A.: Aggression detection in social media: Using deep neural networks, data augmentation, and pseudo labeling. In: *Proceedings of the First Workshop on Trolling, Aggression and Cyberbullying (TRAC-2018)*. pp. 90–97. Association for Computational Linguistics, Santa Fe, New Mexico, USA (Aug 2018), <https://aclanthology.org/W18-4411>
 3. Bastick, Z.: Would you notice if fake news changed your behavior? an experiment on the unconscious effects of disinformation. *Computers in Human Behavior* **116**, 106633 (2021). <https://doi.org/10.1016/j.chb.2020.106633>, <https://www.sciencedirect.com/science/article/pii/S0747563220303800>
 4. Gambino, J.O.J.: Sentiment polarity prediction of Twitter users' opinions to national newspapers news. Ph.D. thesis, Centro de Investigación en Computación (June 2019)
 5. Goel, A., Gautam, J., Kumar, S.: Real time sentiment analysis of tweets using naive bayes. In: *2016 2nd International Conference on Next Generation Computing Technologies (NGCT)*. pp. 257–261 (2016). <https://doi.org/10.1109/NGCT.2016.7877424>
 6. Greenhow, C., Staudt Willet, K.B., Galvin, S.: Inquiring tweets want to know: #edchat supports for #remoteteaching during covid-19. *British Journal of Educational Technology* **52**(4), 1434–1454 (2021)
 7. Jaca-Madariaga, M., Zarrabeitia-Bilbao, E., Rio-Belver, R., Moens, M.: Sentiment analysis model using word2vec, bi-lstm and attention mechanism. In: *IoT and Data Science in Engineering Management: Proceedings of the 16th International Conference on Industrial Engineering and Industrial Management and XXVI Congreso de Ingeniería de Organización*. pp. 239–244. Springer (2023)
 8. Jimenez, D., Gambino, O.J., Calvo, H.: Pseudo-labeling improves news identification and categorization with few annotated data. *Computación y Sistemas* **26**(1), 183–193 (2022)
 9. Jimenez Zafra, S.M., Martin Valdivia, M.T., Martinez Camara, E., Urena Lopez, L.A.: Studying the scope of negation for spanish sentiment analysis on twitter. *IEEE Transactions on Affective Computing* **10**(1), 129–141 (2019). <https://doi.org/10.1109/TAFFC.2017.2693968>
 10. Kuligowska, K., Kowalczyk, B.: Pseudo-labeling with transformers for improving question answering systems. *Procedia Computer Science* **192**, 1162–1169 (2021). <https://doi.org/10.1016/j.procs.2021.08.119>, <https://www.sciencedirect.com/science/article/pii/S1877050921016082>, knowledge-Based and Intelligent Information Engineering Systems: Proceedings of the 25th International Conference KES2021
 11. Macias, C., Calvo, H., Gambino, O.J.: News intention study and automatic estimation of its impact. In: *Pichardo Lagunas, O., Martínez-Miranda, J., Martínez Seis, B. (eds.) Advances in Computational Intelligence*. pp. 83–100. Springer Nature Switzerland, Cham (2022)
 12. Madni, H.A., Umer, M., Abuzinadah, N., Hu, Y.C., Saidani, O., Alsubai, S., Hamdi, M., Ashraf, I.: Improving sentiment prediction of textual tweets using feature fusion and deep machine ensemble model. *Electronics* **12**(6) (2023). <https://doi.org/10.3390/electronics12061302>, <https://www.mdpi.com/2079-9292/12/6/1302>
 13. Mejova, Y.: *Sentiment analysis: An overview*. University of Iowa, Computer Science Department (2009)

14. Pang, B., Lee, L., Vaithyanathan, S.: Thumbs up? sentiment classification using machine learning techniques (2002). <https://doi.org/10.48550/ARXIV.CS/0205070>, <https://arxiv.org/abs/cs/0205070>
15. Pezoa-Fuentes, C., García-Rivera, D., Matamoros-Rojas, S.: Sentiment and emotion on twitter: The case of the global consumer electronics industry. *Journal of Theoretical and Applied Electronic Commerce Research* **18**(2), 765–776 (2023). <https://doi.org/10.3390/jtaer18020039>, <https://www.mdpi.com/0718-1876/18/2/39>
16. Sanchez, C.M.: Estudio de la intención de noticias y estimación automática de su impacto. Master's thesis, Instituto Politécnico Nacional (2023)
17. Tan, K.L., Lee, C.P., Lim, K.M.: Roberta-gru: A hybrid deep learning model for enhanced sentiment analysis. *Applied Sciences* **13**(6) (2023). <https://doi.org/10.3390/app13063915>, <https://www.mdpi.com/2076-3417/13/6/3915>